Mechanizmy składowania danych i systemy kodowania znaków

Silniki bazodanowe, zestawy znaków i reguły porównywania w MySQL



Plan na najbliższe 30 minut

01

Silniki składowania

InnoDB, MyISAM, MEMORY, ARCHIVE i jak je dobierać

02

Kodowanie znaków

Character set, collation i najważniejsze zestawy

03

Hierarchia ustawień

Serwer, baza, tabela, kolumna i połączenie

04

Praktyka

Dobre rady projektowe i podsumowanie

Dwie decyzje, które kształtują bazę danych



Silnik składowania

Mechanizm, który fizycznie zapisuje, odczytuje i indeksuje wiersze tabeli.

Decyduje o wydajności, trwałości, blokadach i transakcjach.



Kodowanie i collation

Sposób zapisu tekstu w bajtach oraz reguły jego porównywania i sortowania.

Decyduje o tym, czy „ą” i „ł” będą poprawne.

Obie decyzje podejmujemy per tabela — kodowanie nawet per kolumna.

Czym jest silnik składowania

- Komponent serwera odpowiedzialny za fizyczną implementację tabeli
- Format plików na dysku i sposób indeksowania
- Blokady przy współbieżnym dostępie
- Opcjonalnie: obsługa transakcji
- Przypisywany przy tworzeniu tabeli lub zmieniany później

```
-- przy tworzeniu tabeli
CREATE TABLE zamowienia (
  id_zamowienia INT PRIMARY KEY,
  klient_id INT,
  data_zlozenia DATE
) ENGINE = InnoDB;

-- zmiana silnika
ALTER TABLE zamowienia
  ENGINE = MyISAM;

-- który silnik?
SHOW TABLE STATUS
  LIKE 'zamowienia';
```

InnoDB — silnik transakcyjny



Transakcje ACID
START TRANSACTION, COMMIT, ROLLBACK



Klucze obce
Integralność referencyjna w silniku



Blokady na poziomie wiersza
Wielu użytkowników pisze równolegle



Indeks klastrowy
Wiersze ułożone wg klucza głównego



Odzyskiwanie po awarii
Dziennik transakcji (redo log)

DOMYŚLNY

InnoDB

Sklepy internetowe, banki, księgowość, CRM i ERP — wszędzie, gdzie zamówienie bez klienta jest niedopuszczalne.

MyISAM — szybkość kosztem transakcyjności

Mocne strony

- Wbudowane wyszukiwanie pełnotekstowe (FULLTEXT)
- Spakowane indeksy — mniejsze pliki
- Bardzo dobry przy przewadze odczytów

Ograniczenia

- Brak transakcji — zmiany natychmiastowe i nieodwracalne
- Brak kluczy obcych
- Blokada całej tabeli przy zapisie

Dobry wybór: archiwalne raporty i wyszukiwarki treści tekstowych — nie dane krytyczne.

MEMORY — tabele w pamięci RAM

RAM

cała tabela w pamięci serwera

0

trwałości — restart kasuje dane

HASH

domyślny typ indeksu (opcjonalnie BTREE)

- Brak obsługi kolumn BLOB i TEXT
- Zastosowania: tabele tymczasowe, tablice przeglądowe, cache sesji
- Nigdy jako magazyn danych trwałych

ARCHIVE — kompresja i dane tylko do dopisywania

Tylko INSERT i SELECT
Brak UPDATE i DELETE pojedynczych wierszy

Silna kompresja zlib
Znacznie mniejsze zużycie miejsca na dysku

Wolniejszy odczyt losowy
Praktycznie brak indeksów poza kluczem głównym

Naturalne zastosowania

- logi zdarzeń
- dane audytowe
- historia transakcji

Dane, których nikt nie modyfikuje — i które rzadko się czyta.

Silniki w pigułce

Silnik	Transakcje	Klucze obce	Blokada	Typowe zastosowanie
InnoDB	Tak	Tak	wiersz	systemy transakcyjne, e-commerce
MyISAM	Nie	Nie	tabela	raporty, wyszukiwanie pełnotekstowe
MEMORY	Nie	Nie	tabela	dane tymczasowe, cache
ARCHIVE	Nie	Nie	— (tylko insert)	logi, archiwa, dane audytowe

Tylko InnoDB łączy transakcje, klucze obce i blokady wierszowe.

Silnik dobieramy do charakteru danych

Zamówienia, płatności, klienci	**InnoDB**
Tabele tymczasowe, cache sesji	**MEMORY**
Logi zdarzeń, dane audytowe	**ARCHIVE**
Archiwalne raporty, pełnotekst	**MyISAM**



Można mieszać silniki w jednej bazie — tabela transakcyjna w InnoDB, jej logi w ARCHIVE.

Dziś InnoDB jest bezpiecznym punktem wyjścia; inne silniki wybieramy świadomie, z konkretnego powodu.

Character set a collation — dwa różne pojęcia

Zestaw znaków

Definiuje, jakie znaki istnieją i jak są kodowane bajtowo — np. ile bajtów zajmuje jeden znak.

Reguły porównywania

Definiują, jak teksty są porównywane i sortowane — czy wielkość liter ma znaczenie, gdzie sortuje się „ą”.

Każdy zestaw znaków ma domyślną collation — zwykle wystarczy wskazać sam zestaw.

Najważniejsze zestawy znaków

Zestaw	Opis	Bajty na znak
utf8mb4	Pełny Unicode — nowoczesny standard	1–4
utf8	Unicode w wersji historycznej (utf8mb3)	1–3
latin2	ISO-8859-2, standard środkowoeuropejski	1
cp1250	Windows-1250, języki środkowoeuropejskie	1
cp852	Strona kodowa DOS	1

```
SHOW CHARACTER SET;

SHOW COLLATION;

SHOW COLLATION
  LIKE 'latin2%';
```

W nowych projektach wybieramy utf8mb4 — utf8 w MySQL to tylko 3 bajty na znak.

Jak czytać nazwy reguł porównywania

`_general_ci`

Bez rozróżniania wielkości liter

Uproszczone sortowanie znaków narodowych

`_bin`

Porównanie binarne, bajt po bajcie

Najściślejsze, ale najmniej językowe

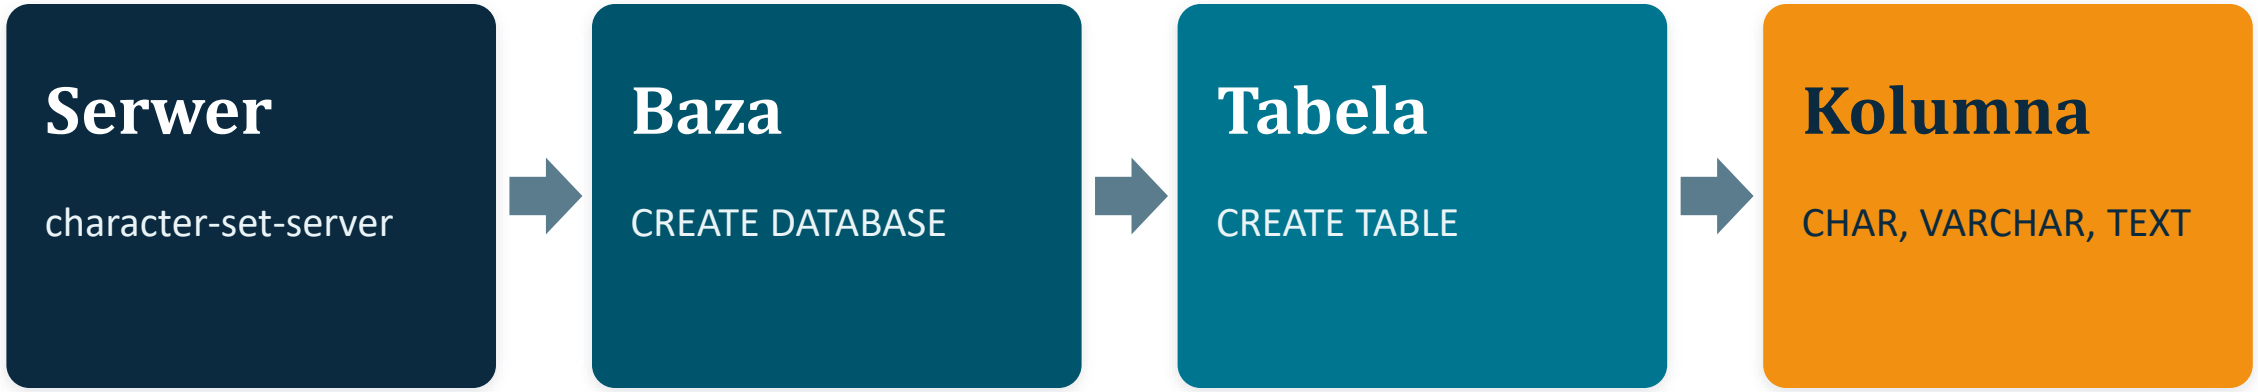
`_polish_ci`

Polska kolejność alfabetyczna

Poprawne ą, ć, ł, ń, ó, ś, ź, ż

Przykłady: utf8_polish_ci, cp1250_general_ci, latin2_bin.

Cztery poziomy — i dziedziczenie



Niższy poziom dziedziczy ustawienie z wyższego — dopóki go jawnie nie nadpiszemy.

Ustawienie serwera jest domyślne dla nowych baz, ustawienie bazy dla nowych tabel, a tabeli dla jej kolumn.

Poziom serwera i bazy danych

Serwer (my.ini / my.cnf)

```
character-set-server = utf8
collation-server = utf8_general_ci

# lub przy starcie:
mysqld --character-set-server=utf8
```

Baza danych

```
CREATE DATABASE sklep
  CHARACTER SET latin2
  COLLATE latin2_bin;

ALTER DATABASE sklep
  CHARACTER SET utf8
  COLLATE utf8_polish_ci;
```

Zmiana na poziomie bazy dotyczy tabel tworzonych później — istniejące zachowują swoje ustawienia.

Poziom tabeli i kolumny

```
CREATE TABLE klienci (
  id INT PRIMARY KEY,
  nazwa VARCHAR(50)
    CHARACTER SET utf8
    COLLATE utf8_polish_ci,
  kod_pocztowy VARCHAR(10)
    CHARACTER SET cp1250
) CHARACTER SET utf8;
```

Co tu się dzieje?

- Tabela domyślnie używa utf8
- Kolumna kod_pocztowy nadpisuje to na cp1250
- Przydatne przy migracji ze starszych systemów

Dotyczy kolumn CHAR, VARCHAR, TEXT oraz ENUM i SET.

Kodowanie połączenia: SET NAMES



zapytania i odpowiedzi — w jakim kodowaniu?

```
SET NAMES 'cp1250';

SET NAMES 'utf8'
  COLLATE 'utf8_polish_ci';
```

Uwaga praktyczna

Kodowanie konsoli klienta musi zgadzać się z SET NAMES. Niezgodność daje „krzaczki” zamiast polskich znaków, a skrajnie — nagłe zakończenie pracy klienta.

Pięć praktycznych zasad



Ustalaj kodowanie świadomie
Nie polegaj na domyślnych ustawieniach serwera.



Zachowuj spójność w bazie
Różne zestawy utrudniają JOIN — wtedy CONVERT(… USING …).



Dobieraj collation do języka
Dla polskich nazw wybierz wariant _polish_ci.



Silnik dobieraj do danych
Mieszanka InnoDB i ARCHIVE w jednej bazie jest w porządku.



MEMORY tylko tymczasowo
Restart lub awaria zasilania kasuje zawartość.

Podsumowanie

Zagadnienie	Kluczowa decyzja	Gdzie ustawiamy
Silnik składowania	InnoDB / MyISAM / MEMORY / ARCHIVE	ENGINE = w CREATE / ALTER TABLE
Zestaw znaków	utf8mb4 / utf8 / latin2 / cp1250	serwer, baza, tabela, kolumna
Reguły porównywania	_general_ci / _bin / _polish_ci	serwer, baza, tabela, kolumna
Kodowanie połączenia	zgodne z klientem	SET NAMES

Silnik decyduje, jak bezpiecznie i wydajnie zapisujemy dane. Kodowanie decyduje, czy tekst jest poprawnie przechowywany, wyświetlany i sortowany.

Dziękuję za uwagę

Pytania sprawdzające do samodzielnego przemyślenia

- Blokada wiersza a blokada tabeli — który silnik którą stosuje?
- Dlaczego ARCHIVE nie pozwala na UPDATE i DELETE, a mimo to się przydaje?
- Czym różni się character set od collation?
- Co grozi przy JOIN kolumn o różnych zestawach znaków?
- Dlaczego wybór silnika i kodowania są niezależne?